

Chapitre 2

Concepts probabilistes

2.1 Probabilités dans la vie de tous les jours

Exemples :

La probabilité qu'il pleuve, impose à beaucoup d'entre-nous sa manière de s'habiller chaque matin.

On traverse la rue sachant que la probabilité d'être renversé par une voiture est faible, mais beaucoup plus grande que la probabilité que le soleil ne se lève pas le lendemain matin.

Comment le sait-on? Par expérience : on connaît tous des gens qui se sont fait renverser, mais on n'a jamais vu le soleil ne pas se lever le matin. On peut même estimer la probabilité d'être renversé : elle doit être inférieure à $1/1000$, parce qu'on a traversé la rue des milliers de fois sans être écrasé. Bien sûr, on peut être renversé demain, ou bien on a pu être renversé la première fois qu'on a traversé une rue. Ces exemples illustrent la connaissance intuitive qu'on a des probabilités.

Notre intuition peut aller plus loin. Considérons les voyages en avion. Est-il prudent de prendre l'avion ? Statistiquement, il y a une chance sur 10 000 000 qu'un avion s'écrase lors d'un vol, et il y a environ 100 000 vols commerciaux par jour. Alors tous les 100 jours il y a une « chance » raisonnable qu'un crash ait lieu. Cette estimation est en accord raisonnable avec ce que l'on peut lire dans les media. Si vous vivez 80 ans et que vous prenez l'avion 5 fois par an, la probabilité que vous subissiez un crash d'avion au cours de votre vie est très faible et prendre l'avion n'est pas très risqué.

Pour tester vos connaissances actuelles sur les probabilités ; Voici quelques exercices simples :

Exercice 2.1

Une urne contient 2 boules oranges, 5 bleues, 3 rouges, 4 noires. On tire au hasard une boule. Trouver la probabilité que (a) la boule soit orange (b) rouge, (c) orange ou bleue.

Solution :

(a) : $2/14 = 0.143$; (b) $3/14 = 0.214$; (c) $(2+5)/14 = 0.5$.

Exercice 2.2

Un garçon lance une paire de dés . Trouver la probabilité que (a) les deux dés affichent le même nombre, (b) les deux dés affichent un nombre plus petit que 5, (c) les deux dés affichent un nombre pair, (d), le produit des deux nombres affichés est 12.

Solution :

$$(a) \frac{1}{36} \times 6 = \frac{1}{6} \quad (b) \frac{4}{6} \times \frac{4}{6} = \frac{4}{9}; \quad (c) \frac{3}{6} \times \frac{3}{6} = \frac{1}{4} \quad (d) \text{ On a } 12 = 2 \times 6 = 3 \times 4. \text{ Donc la solution}$$

$$\text{est : } 2 \times \frac{1}{36} + 2 \times \frac{1}{36} = \frac{1}{9}$$

Exercice 2.3 :

Un garçon joue à pile ou face. Il a tiré face 16 fois sur 25. Quelle est la probabilité qu'il tire face à son 26^{ème} lancer.

Solution : 1/2 (attention au raisonnement erroné)

Exercice 2.4

Supposons qu'on vous propose le choix suivant : vous gagnez 10€ si vous lancez un dé quel que soit le résultat obtenu, ou bien vous gagnez 36€ si la face 5 ou la face 6 sort, et rien sinon. Donnez vos arguments justifiant de votre choix.

Solution :

Si vous vous voulez avoir la plus grande chance d'avoir un gain, le choix 1 est le meilleur puisqu'il correspond à une probabilité de 1 alors que le second correspond à une probabilité de 2/6.

Si vous vous intéressez au plus fort gain possible le choix 2 est le meilleur puis qu'il correspond à un gain moyen probable de $36 \times 2/6 = 12\text{€}$, tandis que le choix 1 correspond à un gain moyen probable de 10€ seulement.

2.2 Règles des probabilités

On résume ici les règles et concepts élémentaires de la théorie des probabilités.

Supposons qu'un processus ou une opération conduise à différents **événements** possibles. L'opération peut être le lancer d'une pièce de monnaie ou d'un dé à six faces par exemple. On appellera chaque lancer un **essai** (un événement est le résultat d'un essai). La liste de tous les événements possibles est appelé **espace d'échantillonnage**. On suppose d'autre part que tous les événements élémentaires sont **mutuellement exclusifs**, c'est à dire que si un événement se réalise, les autres ne peuvent pas se réaliser en même temps. On appelle **n** le nombre

d'évènements, c'est à dire le cardinal de l'espace d'échantillonnage. On numérote les évènements par un indice i variant de 1 à n . Pour l'instant, on a supposé que l'espace d'échantillonnage est un ensemble discret et fini. Par exemple, pour le lancer d'une pièce de monnaie, l'espace d'échantillonnage est {Face, Pile} et donc $n = 2$. Pour le lancer de dés, l'espace d'échantillonnage est l'ensemble des six faces possibles du dé, et $n = 6$.

À chaque événement i on assigne la probabilité $P(i)$ qui satisfait les conditions suivantes :

$$\forall i, P(i) \geq 0 \quad (2.1)$$

et

$$\sum_{i=1}^n P(i) = 1 \quad (2.2)$$

$P(i) = 0$ implique que l'événement ne peut pas avoir lieu (on l'appelle événement impossible), et $P(i) = 1$ implique que l'événement doit avoir lieu; on l'appelle événement certain. La condition de normalisation (2.2) traduit le fait que la somme des probabilités de tous les évènements mutuellement exclusifs possibles est égale à l'unité.

On appelle *variable aléatoire ou stochastique* une quantité pouvant prendre un certain nombre de valeurs déterminées par le résultat d'une expérience. Par exemple, lors d'un lancer de dés, la valeur faciale du résultat est 1, 2, 3, 4, 5 ou 6. La variable aléatoire x_i avec i variant de 1 à 6 peut donc prendre une de ces valeurs avec la probabilité $P(x_i)$.

Il y a plusieurs interprétations possibles au concept de probabilités, valables du moment qu'elles satisfont aux définitions (2.1) et (2.2).

L'interprétation la plus simple à comprendre est fondée sur la *symétrie*. Considérons le lancer d'une pièce de monnaie qui peut conduire à deux événements possibles: Pile ou Face. Si la pièce est parfaite, on peut, en utilisant un argument de symétrie, prédire que chaque événement a la même chance de se produire, i.e. $P(\text{Pile}) = P(\text{Face}) = 1/2$. Par les mêmes arguments de symétrie pour un lancer de dé à six faces non pipé, la probabilité d'obtenir une des six faces vaut pour chaque face $P(i) = 1/6$. On peut estimer aussi les probabilités *a posteriori*, c'est à dire en comptant le nombre d'évènements réalisés à la suite d'un grand nombre d'essais .

Règle d'addition

Supposons connue la probabilité d'obtenir une des faces d'un dé après un lancer ; elle vaut 1/6. On veut connaître la probabilité d'obtenir la face 3 *ou* la face 6 lors d'un lancer. Dans ce cas, on veut connaître la probabilité d'un essai qui est une combinaison de plusieurs opérations élémentaires dont on connaît déjà les probabilités. On veut donc savoir la probabilité de

l'événement i ou j où i est distinct et *mutuellement exclusif* de j . La règle d'addition nous dit que :

$$P(i \text{ ou } j) = P(i) + P(j) \quad (2.3)$$

La relation (2.3) est généralisable à plusieurs événements. Une conséquence importante obtenue de (2.3) et (2.2) est que si $P(i)$ est la probabilité de l'événement i , alors la probabilité que l'événement n'ait pas lieu est $1-P(i)$:

$$P(\text{non } i) = 1 - P(i) \quad (2.4)$$

Exercice 2.5

Quelle est la probabilité de ne pas obtenir un 6 lors d'un lancer de dé ?

Solution

C'est la probabilité d'obtenir les faces 1, 2, 3, 4 ou 5. La règle d'addition donne donc :

$$P(\text{non } 6) = P(1) + P(2) + P(3) + P(4) + P(5) = 1 - P(6) = \frac{5}{6}$$

Règle de multiplication

Une autre règle importante est celle qui donne la probabilité de l'occurrence conjointe de deux événements *indépendants*. Par exemple, quelle est la probabilité d'obtenir un 3 lors d'un lancer de dé et un 6 lors d'un second lancer ?

Si deux événements sont indépendants, la probabilité que les deux événements aient lieu est le produit de leurs probabilités respectives :

$$P(i \text{ et } j) = P(i)P(j) \quad (2.5)$$

Deux événements sont *indépendants* si l'occurrence d'un événement ne change pas la probabilité de l'occurrence du second.

Pour comprendre l'applicabilité de la règle (2.5) et la notion d'indépendance de deux événements, considérons l'exemple suivant. On veut déterminer la probabilité qu'une personne adulte tirée au hasard soit une femme de taille supérieure à 1m80. Supposons qu'on connaisse la probabilité qu'une personne adulte soit de taille supérieure à 1m80 : $P(\geq 1\text{m}80) = 1/5$, et que la probabilité d'être de sexe féminin soit $P(F) = 1/2$. On pourrait conclure en utilisant la règle de multiplication que la probabilité d'être une femme de plus d'1m80 est : $P(F) \times P(\geq 1\text{m}80) = 1/2 \times 1/5 = 1/10$. Ce résultat est faux, car la probabilité d'être une femme grande est différente de la probabilité d'être un homme grand. Être une femme et avoir une taille supérieure à 1m80 ne sont pas des événements indépendants. Parcontre, calculons la probabilité d'être une femme née un 14 juillet. Si on néglige les années bissextiles, par raison de symétrie on peut supposer que la probabilité de naître un 14 juillet est $1/365$. Donc en

appliquant la règle de multiplication, la probabilité d'être une femme née un 14 juillet est $1/2 \times 1/365 = 1/730$. Ce résultat est correct car être une femme et être né un 14 juillet sont deux événements indépendants.

Exercice 2.6

Quelle est la probabilité que lors de deux lancers de dés successifs, au moins une fois la face 6 apparaisse ?

Solution

On sait que $P(6) = \frac{1}{6}$ et $P(\text{non } 6) = \frac{5}{6}$

Il a quatre événements possibles : (6,6), (6, non 6), (non 6, 6), (non 6, non 6), avec les probabilités suivantes :

$$\begin{aligned} P(6,6) &= \frac{1}{6} \times \frac{1}{6} = \frac{1}{36} \\ P(6,\text{non } 6) &= P(\text{non } 6,6) = \frac{1}{6} \times \frac{5}{6} = \frac{5}{36} \\ P(\text{non } 6, \text{non } 6) &= \frac{5}{6} \times \frac{5}{6} = \frac{25}{36} \end{aligned}$$

Tous les événements à l'exception du dernier ont au moins un 6. Donc la probabilité d'obtenir au moins un 6 est :

$$P(\text{au moins un } 6) = P(6,6) + P(6, \text{non } 6) + P(\text{non } 6,6) = \frac{1}{36} + \frac{5}{36} + \frac{5}{36} = \frac{11}{36}$$

Un autre moyen plus direct d'obtenir le résultat est d'utiliser la condition de normalisation :

$$P(\text{au moins un } 6) = 1 - P(\text{non } 6, \text{non } 6) = 1 - \frac{25}{36} = \frac{11}{36}$$

Procédure de normalisation

Souvent on connaît les probabilités des événements à un facteur multiplicatif près. Par exemple, on peut savoir que $P(1) = 2P(2)$, sans connaître séparément $P(1)$ ni $P(2)$. Supposons que l'on sache pour tout événement i de l'espace d'échantillonnage que $P(i)$ est proportionnel à une fonction connue $f(i)$. Pour obtenir la distribution de probabilité normalisée, c'est à dire obéissant à la définition (2.2), on divise chaque $f(i)$ par la somme de toutes les probabilités non normalisées. C'est à dire si $f(i) \propto P(i)$ et $Z = \sum_{i=1}^n f(i)$, alors $P(i) = f(i)/Z$. Cette procédure appelée *normalisation* sera d'une utilité constante en physique statistique.

Exercice 2.7 Une classe est notée par valeur décroissante de A à D. On suppose qu'il y a trois fois plus de notes C que de notes A, et deux fois plus de notes B que de notes A, est quatre fois moins de notes D que de notes A. Tous les élèves ont une note. Quelle est la probabilité pour un élève d'avoir respectivement les notes A, B, C et D ?

Solution :

On choisit d'abord une probabilité non normalisée telle que $f(A) = 1$. Alors $f(B) = 2$, $f(C) = 3$ et $f(D) = 1/4$. $Z = \sum_i f(i) = 1 + 2 + 3 + 0.25 = 6.25$. On en déduit $P(A) = 1/6.25 = 0.16$,

$$P(B) = 2 / 6.25 = 0.32, P(C) = 3/6.25 = 0.48, P(D) = 0.25/6.25 = 0.04$$

2.3 Valeurs moyennes et moments d'une distribution

La donnée de la distribution de probabilité normalisée $P(x_1), P(x_2), \dots, P(x_n)$ d'une variable aléatoire x constitue une description statistique complète du système. Cependant, dans de nombreux cas, il est plus pratique de décrire la distribution des valeurs possibles de x de manière moins détaillée; La donnée la plus familière est la *valeur moyenne* ou *moyenne* de la variable aléatoire x notée $\bar{x}$. Par définition la valeur moyenne de x est :

$$\begin{aligned} \bar{x} &\equiv x_1 P(x_1) + x_2 P(x_2) + \dots x_n P(x_n) \\ &= \sum_i x_i P(x_i) \end{aligned} \quad (2.6)$$

Si f est une fonction de x , la valeur moyenne de $f(x)$ est définie par :

$$\overline{f(x)} = \sum_{i=1}^n f(x_i) P(x_i) \quad (2.7)$$

Si f et g sont deux fonctions de x , alors :

$$\begin{aligned} \overline{f(x) + g(x)} &= \sum_{i=1}^n (f(x_i) + g(x_i)) P(x_i) \\ &= \sum_{i=1}^n f(x_i) P(x_i) + \sum_{i=1}^n g(x_i) P(x_i) \\ &= \overline{f(x)} + \overline{g(x)} \end{aligned} \quad (2.8)$$

De même, si c est une constante

$$\overline{cf(x)} = c \overline{f(x)} \quad (2.9)$$

les propriétés (2.8) et (2.9) traduisent la linéarité de la valeur moyenne.

Plus généralement, on définit le *moment d'ordre m* de la distribution P par :

$$\overline{x^m} = \sum_{i=1}^n x_i^m P(x_i) \quad (2.10)$$

La moyenne de x est le moment d'ordre 1 de la distribution de probabilité. On remarque aussi que le moment d'ordre 0 vaut 1.

La valeur moyenne de x est une mesure de la valeur centrale de x autour de laquelle les différentes valeurs de x possibles sont distribuées. Si on mesure x à partir de sa moyenne on a :

$$\Delta x = x - \bar{x} \quad (2.11)$$

et

$$\overline{\Delta x} = \overline{x - \bar{x}} \equiv \bar{x} - \bar{x} = 0 \quad (2.12)$$

La valeur moyenne de la déviation de x par rapport à sa moyenne est nulle.

Si seul l'évènement j est possible, on a $P(i) = 1$ pour $i = j$ et $P(i) = 0$ sinon. La distribution de probabilité à une largeur nulle. Dans le cas général où plusieurs évènements sont possibles, la largeur de la distribution est donnée par :

$$\overline{\Delta x^2} \equiv \overline{(x - \bar{x})^2} \quad (2.13)$$

la quantité $\overline{\Delta x^2}$ est appelée *variance* ou *dispersion* de la distribution. Sa racine carrée est appelée *déviatation standard* ou *écart-type*. Il est facile de voir que plus la distribution des valeurs possibles de x est large, plus grande est la variance. Une autre forme de la variance peut être établie :

$$\overline{(x - \bar{x})^2} = \overline{(x^2 - 2x\bar{x} + \bar{x}^2)} = \overline{x^2} - 2\bar{x}\bar{x} + \bar{x}^2$$

soit :

$$\overline{\Delta x^2} = \overline{x^2} - \bar{x}^2 \quad (2.14)$$

Comme $\overline{\Delta x^2}$ est toujours positif, on a $\overline{x^2} \geq \bar{x}^2$.

La variance représente le carré de la largeur de la distribution. Il est utile d'interpréter la largeur de la distribution comme étant la *déviatation standard* ou *écart-type* de la distribution de probabilité $P(x)$:

$$\sigma = \sqrt{\overline{\Delta x^2}} = \sqrt{\overline{x^2} - \bar{x}^2} \quad (2.15)$$

Exercice 2.8

Trouver la valeur moyenne et l'écart type de la valeur faciale obtenue par le lancer d'un seul dé .

Solution

$$\bar{x} = \frac{7}{2} = 3.5 ; \overline{x^2} = \frac{91}{6} ; \overline{\Delta x^2} = \frac{35}{12} ; \sigma = 1.71$$

Exercice 2.9

En moyenne combien de fois faut-il lancer un dé pour obtenir un 6 ?

Solution

La réponse semble évidente : six fois. Démontrons là.

Soit $p=1/6$, la probabilité d'obtenir un 6 pour un lancer et $q=1-p$. La probabilité de tirer un 6 pour la première fois au lancer i est donnée dans le tableau ci-dessous :

essai	Probabilité de succès à l'essai i
1	p
2	qp
3	q^2p
4	q^3p
.	.
.	.
i	$q^{i-1}p$

La somme de toutes les probabilités est $p + pq + pq^2 + ..pq^{i-1} + .. = p \sum_{i=0}^{+\infty} q^i = \frac{p}{1-q} = 1$. Elle est

donc bien normalisée. Le nombre moyen d'essais m est :

$$\begin{aligned}
 m &= p + 2pq + 3pq^2 + 4pq^3 + .. + ipq^{i-1} + .. \\
 &= p(1 + 2q + 3q^2 + 4q^3 + ...) \\
 &= p \frac{d}{dq} (1 + q + q^2 + q^3 + ..) \\
 m &= p \frac{d}{dq} \frac{1}{1-q} = \frac{p}{(1-q)^2} = \frac{1}{p}
 \end{aligned}$$

2.4 Types de probabilités

Comment donner une valeur à une probabilité ? la réponse dépend de l'information dont on dispose. On peut soit faire une hypothèse indépendante sur la distribution de probabilités basée sur des conditions de symétries, ou bien on peut faire une estimation empirique de cette distribution.

La méthode empirique est appelée **échantillonnage**, elle équivaut à répéter un grand nombre de fois un essai sur un *même* système et dans les mêmes conditions et de compter combien de fois chaque événement se produit (on fait un histogramme) . Soit M le nombre d'essai, et M_i , le

nombre de fois que l'événement i se produit, le rapport M_i/M tend vers une valeur fixe lorsque M devient de plus en plus grand. On peut estimer la probabilité $P(i)$ comme :

$$P(i) \approx \frac{M_i}{M} \quad (M \text{ nombre d'essais}) \quad (2.16)$$

Une autre méthode empirique pour estimer une distribution de probabilité est de faire un seul essai sur un grand nombre de répliques ou copies du système qu'on considère. Par exemple, au lieu de lancer 100 fois une seule pièce, on lance 100 pièces identiques en une seule fois. La fraction de pièces qui afficheront face donnera une estimation de la probabilité de cet événement. Une collection de systèmes identiques est appelée *ensemble statistique* et la probabilité qu'un événement se produise est estimée à partir de cet ensemble. L'ensemble statistique consiste en un grand nombre M de systèmes identiques. Si M_i désigne le nombre de systèmes identiques qui réalisent l'événement i ; la fraction $P(i)$ est une estimation de la probabilité de l'événement i .

$$P(i) \approx \frac{M_i}{M} \quad (M \text{ nombre de systèmes de l'ensemble statistique}) \quad (2.17)$$

Si le système qu'on étudie n'évolue pas dans le temps, il est raisonnable de penser que la détermination de la distribution de probabilité par une série de mesures successives sur un seul système sera très voisine de la probabilité estimée par une seule mesure sur un grand nombre de systèmes identiques.

Simulation 2.1

Ouvrir « cointoss »

On prend une pièce non faussée probabilité de tire face : $\frac{1}{2}$

On choisit une pièce $N=1$.

Observer comment évolue le rapport du nombre de résultats face par rapport au nombre d'essais. Obtient-on le résultat attendu (lequel ?) pour 100 coups ? 10 000 coups ? Comment simuler une pièce faussée (côté face plus lourd par exemple)

On choisit maintenant $N=100$. On fait un seul essai. Faire la même chose pour 10 000 pièces. Cette fois ci, on effectue le lancer de 100 pièce plusieurs fois ; Observer l'évolution de l'histogramme du nombre de faces tirés à chaque essai en fonction du nombre d'essai. Quelle est l'allure de la courbe ? maximum ? largeur ?

Beaucoup de gens croient de manière erronée, que si un événement n'a pas été réalisé un certain nombre de fois, alors la probabilité qu'il se réalise la fois suivante est plus grande.

Exemple : on joue à pile ou face. On obtient pile cinq fois de suite, donc on pense que la probabilité d'obtenir face la sixième fois est supérieure à $\frac{1}{2}$. En réalité ce raisonnement est faux, puisque chaque lancer de pièce constitue un événement indépendant du précédent, donc la probabilité restera $\frac{1}{2}$ comme pour les lancers précédents.

Cette discussion montre que la définition de la probabilité d'un événement à partir de la fréquence de réalisation de cet événement n'est pas réellement satisfaisante. En effet elle présuppose que tous les essais successifs sont indépendants, c'est à dire que les fréquences de réalisation d'un essai seront les mêmes dans le futur que dans le passé, de plus il faut faire un très grand nombre d'essais pour avoir une bonne mesure, sans qu'on sache combien sont nécessaires.

Probabilités conditionnelles

Exemple : Supposons qu'un couple ait deux enfants dont l'un au moins est une fille. (a) Quelle est la probabilité que l'autre enfant soit une fille ? (b) supposons qu'on sache en plus que l'aîné est une fille. Quelle est la probabilité que le plus jeune soit une fille ?

En l'absence de toute information les événements $\{F,F\}$, $\{F,G\}$, $\{G,F\}$, $\{G,G\}$ sont équiprobables. Or on sait que l'événement $\{G,G\}$ est impossible. Donc $P(\{G,G\})=0$. (a) Parmi les trois événements restant possibles, seul $\{F,F\}$ correspond à la réalisation demandée. Donc la probabilité recherchée est $\frac{1}{3}$. (b) Cette fois ci, on sait de plus que $P(\{G,F\})=0$, puisque l'aîné est une fille. Donc la probabilité recherchée est $\frac{1}{2}$.

On définit et on note $P(A|B)$, la probabilité que l'événement A se réalise sachant que B est réalisé (probabilité *conditionnelle*). On a, en notant non $B = \bar{B}$:

$$P(A) = P(A|B) + P(A|\bar{B}) \quad (2.18)$$

Alors il est clair que :

$$P(A \text{ et } B) = P(A|B)P(B) = P(B|A)P(A) \quad (2.19)$$

L'équation (2.19) exprime que la probabilité que A et B se réalisent est égale à la probabilité que A se réalise sachant que B est réalisé multipliée par la probabilité que B se réalise, ce qui est identique à la probabilité que B se réalise sachant que A est réalisé multipliée par la probabilité que A se réalise.

Si on s'intéresse à plusieurs événements A_i possibles pour un même événement B , on peut généraliser (2.19) :

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{P(B)} \quad (2.20)$$

Si tous les événements A_i sont mutuellement exclusifs, et que l'un au moins doit se réaliser, on peut aussi écrire que :

$$P(B) = \sum_j P(B|A_j)P(A_j) \quad (2.21)$$

En substituant (2.21) dans (2.20), on obtient le **théorème de Baye** :

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_j P(B|A_j)P(A_j)} \quad (2.22)$$

Exercice 2.10

Même si vous ne présentez aucun symptôme, votre, médecin veut tester si vous avez une maladie rare, que seule 1 personne sur 10 000 de votre âge contracte. Le test est fiable à 98%, ce qui signifie que si vous avez la maladie, le test sera positif dans 98% des cas et négatif dans 2%. De plus on suppose que si vous n'avez pas la maladie, le test sera négatif à 98% et positif à 2%. Vous faites le test, il s'avère positif. Quelle est la probabilité que vous soyez atteint de la maladie ? Le test est-il utile ?

Solution

$P(+|M) = 0.98$ représente la probabilité d'être testé positif en ayant la maladie. En notant $\bar{M}$ le fait de ne pas avoir la maladie et $-$ le fait d'être testé négatif, on a $P(-|M) = 0.02$, $P(-|\bar{M}) = 0.98$, $P(+|\bar{M}) = 0.02$, $P(M) = 0.0001$ et $P(\bar{M}) = 0.9999$.

En appliquant le théorème de Baye, la probabilité d'être malade, ayant été testé positif est :

$$P(M|+) = \frac{P(+|M)P(M)}{P(+|M)P(M) + P(+|\bar{M})P(\bar{M})} = \frac{0.98 \times 0.0001}{0.98 \times 0.0001 + 0.02 \times 0.9999} = 0.0047 = 0.47\%$$

On constate donc que le test n'est pas utile.

2. 5 Processus de Bernoulli et distribution binomiale

Nous allons maintenant considérer quelques systèmes physiques pour lesquels on peut calculer analytiquement la distribution de probabilité.

Système de moments magnétiques sans interaction

On considère un système de N moments magnétiques (on peut voir un moment magnétique comme une aiguille de boussole microscopique) sans interaction chacun possédant un spin $\frac{1}{2}$ (le spin est une grandeur purement quantique). Chacun de ces moments magnétique prend la valeur μ en présence d'un champ magnétique extérieur B . On suppose que le champ B est dirigé suivant l'axe Oz dans le sens des z positifs. Spin $\frac{1}{2}$ signifie que le spin peut pointer dans deux directions seulement : soit dans la direction $+z$ (parallèle à B), soit dans la direction $-z$ (antiparallèle à B). L'énergie d'interaction de chaque spin dans le champ magnétique B est : $E = \mp \mu B$ suivant l'orientation $\pm$ du spin. Ce modèle est une simplification de systèmes magnétiques plus réalistes.

On note p la probabilité que le spin soit $+\frac{1}{2}$ (dans la direction $+z$) et q la probabilité qu'il soit $-\frac{1}{2}$ (dans la direction $-z$). L'espace d'échantillonnage pour un spin se réduit à $\{+\frac{1}{2}, -\frac{1}{2}\}$, donc $p + q = 1$. Si $B = 0$, il n'y a pas de sens privilégié et $p = q = 1/2$. Si $B \neq 0$, on ne sait pas comment calculer p , et pour l'instant on supposera que c'est un paramètre connu. On verra dans un chapitre ultérieur comment calculer p et q quand le système est en équilibre à la température T . À chaque spin i on associe la variable aléatoire s_i qui peut prendre deux valeurs ± 1 avec les probabilités respectives p et q suivant l'orientation du spin. Une des grandeurs macroscopiques qui caractérise le système est sa *magnétisation* ou *moment magnétique total* M défini par :

$$M = \mu(s_1 + s_2 + \dots + s_N) = \mu \sum_{i=1}^N s_i \quad (2.23)$$

Dans la suite, par soucis de simplification on posera $\mu = 1$, si il n'y a aucune ambiguïté. On peut aussi interpréter si on préfère M comme le double de la valeur nette de spins $+\frac{1}{2}$.

On calculera d'abord la valeur moyenne de m , ensuite sa variance, puis la distribution de probabilité $P(M)$ que le système ait un moment magnétique total M . En utilisant (2.6), (2.23) devient :

$$\overline{M} = \overline{\left(\sum_{i=1}^N s_i \right)} = \sum_{i=1}^N \overline{s_i} \quad (2.24)$$

Comme la probabilité qu'un spin quelconque prenne la valeur ± 1 est identique pour tous les spins, la valeur moyenne de chaque spin est la même est vaut : $\overline{s_1} = \overline{s_2} = \dots = \overline{s_N} = \overline{s}$. Alors la somme (2.24) s'écrit :

$$\overline{M} = N\overline{s} \quad (2.25)$$

L'équation (2.25) exprime que le moment magnétique total moyen du système est N fois le moment magnétique d'un seul spin. Comme $\overline{s} = (1 \times p) + (-1 \times q) = p - q$ on a :

$$\overline{M} = N(p - q) \quad (2.26)$$

Calculons maintenant la variance : $\overline{(M - \overline{M})^2}$. On a

$$\Delta M = M - \overline{M} = \sum_{i=1}^N \Delta s_i \quad (2.27)$$

où

$$\Delta s_i \equiv s_i - \bar{s} \quad (2.28)$$

Avant de faire le calcul général, on va le faire pour $N = 3$. Alors :

$$\begin{aligned} (\Delta M)^2 &= (\Delta s_1 + \Delta s_2 + \Delta s_3)(\Delta s_1 + \Delta s_2 + \Delta s_3) \\ &= [(\Delta s_1)^2 + (\Delta s_2)^2 + (\Delta s_3)^2] + 2[\Delta s_1 \Delta s_2 + \Delta s_1 \Delta s_3 + \Delta s_2 \Delta s_3] \end{aligned} \quad (2.29)$$

Le premier terme dans (2.29) représente les trois termes dans la somme multipliés par eux-mêmes. Le second terme représente la somme des termes croisés provient de spins différents.

Comme les différents spins sont *statistiquement indépendants*, on a :

$$\overline{\Delta s_i \Delta s_j} = \overline{\Delta s_i} \overline{\Delta s_j} = 0 \quad (i \neq j) \quad (2.30)$$

car $\overline{\Delta s_i} = 0$. Chaque terme croisé s'annule donc en moyenne. Donc (2.29) se réduit à la somme des termes carrés et comme en moyenne chaque spin est équivalent :

$$\overline{(\Delta M)^2} = \overline{(\Delta s_1)^2} + \overline{(\Delta s_2)^2} + \overline{(\Delta s_3)^2} = 3\overline{(\Delta s)^2} \quad (2.31)$$

La variance de M vaut donc 3 fois la variance d'un seul spin. La variance est une grandeur *additive*.

On généralise facilement ce résultat à N spins et on obtient donc :

$$\overline{(\Delta M)^2} = N\overline{(\Delta s)^2} \quad (2.32)$$

Explicitons l'expression de $\overline{(\Delta s)^2}$. On a $\overline{s^2} = \left[1^2 \times p\right] + \left[(-1)^2 \times q\right] = p + q = 1$. Donc :

$$\overline{(\Delta s)^2} = \overline{s^2} - \bar{s}^2 = 1 - (p - q)^2 = (1 - p + q)(1 + p - q) = (2q)(2p) = 4pq \quad (2.33)$$

Il vient :

$$\overline{(\Delta M)^2} = 4pqN \quad (2.34)$$

A cause de la simplicité d'un système de spins sans interaction, on peut calculer la distribution de probabilité complètement et pas seulement ses premiers moments. On commence par expliciter le cas où $N=3$. Comme chaque spin a seulement deux états possibles (+ ou -), le nombre d'évènements possibles et $2^{N=3} = 8$ représentés sur la figure ci-dessous :




Figure 2.1 Ensemble de $N=3$ spins. Les flèches indiquent la direction du moment magnétique d'un spin. La probabilité de chaque configuration du système est montrée.

Comme chaque spin est indépendant des autres, il est facile de calculer la probabilité de chaque événement en utilisant la règle de multiplication (2.5) comme montré sur la figure 2.1. Bien que chaque élément de l'ensemble d'échantillonnage soit distinct, plusieurs configurations ont le même nombre de spins $+$. Il est alors intéressant de calculer la probabilité $P_N(n)$ que n spins parmi N soient dans l'état $+$ en utilisant la règle d'addition (2.3). Pour $N=3$, on a :

$$\begin{aligned}
 P_3(n=3) &= p^3 \\
 P_3(n=2) &= 3p^2q \\
 P_3(n=1) &= 3pq^2 \\
 P_3(n=0) &= q^3
 \end{aligned}
 \tag{2.35}$$

Exercice 2.11

Calculer le premier moment $\bar{n}$, et la variance $\overline{(\Delta n)^2}$ de la variable aléatoire n

Solution:

$$\bar{n} = 3p \quad ; \quad \overline{(\Delta n)^2} = 3pq$$

Le moment magnétique moyen total est donné par la différence entre le nombre moyen de spins $+$ et le nombre moyen de spins $-$, i.e. : $\bar{M} = (\bar{n} - (3 - \bar{n})) = 3(p - q)$

Processus de Bernoulli

D'autres systèmes peuvent être décrits de manière identique à celui d'une assemblée de N spins sans interaction. Par exemple, la statistique du lancer de N pièces. En identifiant le nombre de pièces au nombre de total de spins, le nombre d'événements « Face » au nombre n de spins $+$, et « Pile » au nombre $N - n$ de spins $-$. Dans le cas où les pièces ne sont pas biaisées, $p = q = 1/2$. Un autre exemple qui sera étudié en TD, est celui de la *marche aléatoire* unidimensionnelle, qui modélise la marche d'un ivrogne, lequel partant d'un lampadaire effectue N pas sur une

route (assimilée à une ligne droite) de longueur identique a . À chaque intervalle de temps, le marcheur peut faire un pas sur la droite avec une probabilité p ou un pas sur la gauche avec une probabilité $q = 1 - p$. Si on appelle n le nombre total de pas faits par le marcheur sur la droite et n' , le nombre total de pas faits sur la gauche, on a $N = n + n'$. La probabilité que le marcheur ait effectué n pas sur la droite après N pas est aussi de la forme $P_N(n)$.

Ces trois exemples (assemblée de spins sans interaction, marche aléatoire unidimensionnelle, et lancer de pièces) sont décrits par la même distribution de probabilité. Ce sont tous des *processus de Bernoulli*. Un processus de Bernoulli est défini comme suit :

- (a) A chaque essai, il y a seulement deux résultats possibles (+ ou – pour les spins, Pile ou face pour les pièces, gauche ou droite pour les pas de l'ivrogne etc.).
- (b) Chaque résultat d'un essai est *indépendant de tous les autres essais antérieurs*.

À cause de l'importance des systèmes magnétiques, on va discuter les processus de Bernoulli à partir de l'exemple d'une assemblée de N spins $\pm 1/2$ sans interaction. La quantité la plus intéressante est $P_N(n)$ que l'on va calculer pour N et n quelconques. On sait que la probabilité qu'un événement particulier correspondant à n spins + et n' spins – se réalise est $p^n q^{n'}$. On écrit alors $P_N(n)$ sous la forme :

$$P_N(n) = W_N(n, n') p^n q^{n'} \quad (2.36)$$

où $n' = N - n$ et $W_N(n, n')$ est le nombre de configurations distinctes de N spins avec n + et n' –.

On a déjà calculé tous les $W_3(n, n')$.

On peut obtenir l'expression générale de $W_N(n, n')$ en établissant une relation de récurrence entre W_N et W_{N-1} . Une configuration comprenant n spins + et n' spins – sur un total de N peut s'obtenir en ajoutant un spin à un total de $N - 1$; le spin additionnel est soit :

- (a) + s'il y a $(n-1)$ spins + et n' spins –, ou bien
- (b) – s'il y a n spins + et $(n'-1)$ spins –


Comme il y a $W_{N-1}(n-1, n')$ configurations correspondant à (a) et $W_{N-1}(n, n'-1)$ configurations correspondant à (b), on obtient la relation de récurrence :

$$W_N(n, n') = W_{N-1}(n-1, n') + W_{N-1}(n, n'-1) \quad (2.37)$$

En commençant par les valeurs connues : $W_0(0,0) = 1$, $W_1(1,0) = W_1(0,1) = 1$, on peut utiliser la relation de récurrence (2.37) pour construire $W_N(n, n')$, pour N quelconque. Par exemple :

$$\begin{aligned} W_2(2,0) &= W_1(1,0) + W_1(2,-1) = 1 + 0 = 1 \\ W_2(1,1) &= W_1(0,1) + W_1(1,0) = 1 + 1 = 2 \\ W_2(0,2) &= W_1(-1,2) + W_1(0,1) = 0 + 1 = 1 \end{aligned}$$

La figure 2.2, connue sous le nom de triangle de Pascal, montre comment calculer les différents $W_N(n, n')$



où on a utilisé le fait que $p + q = 1$. La distribution binomiale est bien normalisée.

Calcul de la valeur moyenne

Par définition :

$$\bar{n} = \sum_{n=0}^N n P_N(n) = \sum_{n=0}^N n \frac{N!}{n!(N-n)!} p^n q^{N-n} \quad (2.42)$$

Pour évaluer la somme (2.42), on va utiliser une technique qui sera très utile dans de nombreux contextes de la physique statistique, basée sur l'égalité :

$$p \frac{d}{dp} p^n = n p^n \quad (2.43)$$

On peut alors réécrire (2.42) sous la forme :

$$\bar{n} = \sum_{n=0}^N \frac{N!}{n!(N-n)!} n p^n q^{N-n} = \sum_{n=0}^N \frac{N!}{n!(N-n)!} \left(p \frac{\partial}{\partial p} p^n \right) q^{N-n} \quad (2.44)$$

On a utilisé le symbole de la dérivation partielle, pour se rappeler que l'opérateur de dérivation n'agit que sur p et pas sur q . En inversant dans (2.44), l'ordre de la sommation et de la dérivation, il vient :

$$\begin{aligned} \bar{n} &= p \frac{\partial}{\partial p} \left[\sum_{n=0}^N \frac{N!}{n!(N-n)!} p^n q^{N-n} \right] \\ &= p \frac{\partial}{\partial p} (p+q)^N = pN(p+q)^{N-1} \end{aligned} \quad (2.45)$$

Comme ce résultat est vrai pour p et q arbitraires, il peut s'appliquer au cas qui nous intéresse : $p + q = 1$. On obtient alors le résultat attendu :

$$\bar{n} = pN \quad (2.47)$$

Calcul des fluctuation relatives :

Pour déterminer $\overline{(\Delta n)^2}$, il faut connaître $\overline{n^2}$ qu'on va calculer en utilisant une technique similaire à celle utilisée pour le calcul de $\bar{n}$:

$$\begin{aligned} \overline{n^2} &= \sum_{n=0}^N n^2 \frac{N!}{n!(N-n)!} p^n q^{N-n} \\ &= \sum_{n=0}^N \frac{N!}{n!(N-n)!} \left(p \frac{\partial}{\partial p} \right)^2 p^n q^{N-n} \\ &= \left(p \frac{\partial}{\partial p} \right)^2 \sum_{n=0}^N \frac{N!}{n!(N-n)!} p^n q^{N-n} = \left(p \frac{\partial}{\partial p} \right)^2 (p+q)^N \end{aligned}$$

$$\begin{aligned}
&= \left(p \frac{\partial}{\partial p} \right) \left[N p (p+q)^{N-1} \right] \\
&= p \left[N (p+q)^{N-1} + p N (N-1) (p+q)^{N-2} \right] \quad (2.48)
\end{aligned}$$

En injectant alors $p+q=1$ dans (2.48), on obtient le résultat recherché :

$$\overline{n^2} = (pN)^2 + p(1-p)N = \bar{n}^2 + pqN \quad (2.49)$$

À partir de (2.49) on obtient la variance :

$$\sigma_n^2 = \overline{(\Delta n)^2} = \overline{n^2} - \bar{n}^2 = pqN \quad (2.50)$$

La largeur relative de la distribution binomiale s'obtient à partir de 2.47 et 2.50 :

$$\frac{\sigma_n}{\bar{n}} = \frac{\sqrt{pqN}}{pN} = \left(\frac{q}{p} \right)^{1/2} \frac{1}{\sqrt{N}} \quad (2.51)$$

On voit que la largeur relative de la distribution binomiale tend vers 0 comme $N^{-1/2}$ quand $N \rightarrow \infty$. Si vous appliquez la formule au cas $N=16$ et $p=q=1/2$, vous pouvez vous rendre compte que la valeur correspond bien à la valeur intuitive que vous pouvez déduire en observant la figure 2.3.

Approximation de Stirling

Très souvent, on aura à évaluer $\ln N!$ pour $N \gg 1$. On peut remarquer tout d'abord qu'avec une calculatrice, il est impossible d'évaluer ce nombre pour $N > 170$, car au delà, $N!$ dépasse les capacités de la calculatrice. Il existe une approximation pour $N!$ connue sous le nom d'*approximation de Stirling* :

$$\ln N! \approx N \ln N - N \quad (2.52)$$

Une approximation encore plus précise est donnée par :

$$\ln N! \approx N \ln N - N + \frac{1}{2} \ln(2\pi N) \quad (2.53)$$

Exercice 2.12

Comparer les approximations (2.52) et (2.53) à la valeur exacte de $N!$ pour $N=5, 10, 20$ et 50 .

Si besoin est, calculer $N!$ en utilisant la relation $\ln N! = \sum_{m=1}^N \ln m$.

L'approximation de Stirling permet aussi de généraliser facilement la notion de factorielle à des nombres non entiers. En utilisant cette généralisation, il est facile de montrer à partir de (2.52) que

$$\frac{d}{dx} \ln x! = \ln x \quad (2.54)$$

2.6 Distribution continue de probabilité

Dans de nombreux cas intéressants en physique, les variables aléatoires sont continues et non pas discrètes, par exemple la position ou la vitesse d'une particule classique. Pour des variables continues, la probabilité d'obtenir une valeur particulière de la variable aléatoire x n'a pas de sens. En effet, comme il y a un nombre infini de valeurs possibles de x sur un intervalle fini ou infini, la probabilité d'obtenir une valeur particulière est nulle. Considérons par exemple la marche aléatoire unidimensionnelle, où le marcheur peut faire un pas à droite ou à gauche aléatoirement avec la même probabilité, mais avec des longueurs de pas qui peuvent être quelconque entre 0 et a . Alors la position x du marcheur est une variable aléatoire continue. On cherche plutôt alors à calculer la probabilité que la position du marcheur soit comprise entre x et $x + \Delta x$ après N pas. On peut supposer que cette probabilité sera proportionnelle à la largeur de l'intervalle Δx , c'est à dire $\Delta P(x, \Delta x) = p(x)\Delta x$. La quantité $p(x)$ est appelée *densité de probabilité*, et on peut écrire la probabilité que la position du marcheur soit comprise entre a et b :

$$P(a \rightarrow b) = \int_a^b p(x)dx \quad (2.55)$$

Notons que la densité de probabilité est une fonction positive et qu'elle a la dimension de $1/x$. Les propriétés des densités de probabilité peuvent être facilement obtenues par une généralisation du cas discret. Par exemple la condition de normalisation est donnée par :

$$\int_{-\infty}^{+\infty} p(x)dx = 1 \quad (2.56)$$

La valeur moyenne d'une fonction $f(x)$ sur l'intervalle $[a, b]$, est donnée par :

$$\overline{f(x)} = \int_a^b f(x)p(x)dx \quad (2.57)$$

Exercice 2.13

Une variable aléatoire x a la densité de probabilité :

$$p(x) = \begin{cases} Ae^{-\lambda x} & \text{si } 0 \leq x \leq \infty \\ 0 & x < 0 \end{cases}$$

- (a) Calculer A . (b) Calculer $\bar{x}$. (c) Quelle est la valeur la plus probable de x , notée $\tilde{x}$? (d)

Choisir $\lambda = 1.0$ et déterminer la probabilité que x ait une valeur inférieure à 0.3.

Solution

(a) $\int_{-\infty}^{+\infty} p(x)dx = 1 \Leftrightarrow A \int_0^{+\infty} e^{-\lambda x} dx = 1 \Leftrightarrow A = \lambda$

$$(b) \bar{x} = \lambda \int_0^{\infty} x e^{-\lambda x} dx = \lambda \left(\left[\frac{-x e^{-\lambda x}}{\lambda} \right]_0^{+\infty} + \frac{1}{\lambda} \int_0^{\infty} e^{-\lambda x} dx \right) = \frac{1}{\lambda}$$

(c) $\tilde{x}$ correspond au maximum de $p(x)$. Comme c'est une fonction strictement décroissante de 0 à ∞ , $\tilde{x} = 0$

$$(d). \int_0^{0.3} e^{-x} dx = (1 - e^{-0.3}) \approx 0.259$$

2.7 La distribution gaussienne comme limite de la distribution binomiale

Pour $N \gg 1$, en utilisant l'approximation de Stirling (2.52), on a pour une distribution binomiale:

$$\ln P_N(n) = N \ln N - N - n \ln n + n - (N - n) \ln(N - n) + (N - n) + n \ln p + (N - n) \ln q \quad (2.58)$$

La distribution admet un maximum pour

$$\left. \frac{d \ln P_N(n)}{dn} \right|_{n=\tilde{n}} = 0 \Leftrightarrow \frac{N - \tilde{n}}{\tilde{n}} = \frac{q}{p} \Leftrightarrow \tilde{n} = \bar{n} = pN \quad (2.59)$$

De plus, pour de grandes valeurs de N , la distribution binomiale peut être approximée par une fonction régulière continue, même si seules les valeurs entières de n sont physiquement possibles. La première étape pour identifier cette fonction continue est de se rendre compte que pour $N \gg 1$, $P_N(n)$ est une fonction qui varie très rapidement autour de son maximum pN . Pour cette raison on ne souhaite pas approximer directement $P_N(n)$. Cependant comme le logarithme de $P_N(n)$ est une fonction qui varie très lentement, on espère qu'un développement en séries de $\ln P_N(n)$ convergera. On effectue donc un développement de $\ln P_N(n)$ en séries de Taylor autour de $n = \tilde{n}$, valeur de n où $P_N(n)$ atteint son maximum. On va plutôt développer $p(n)$ densité de probabilité au séries de Taylor autour du maximum $n = \tilde{n}$, parce qu'on va traiter n comme une variable continue.

$$\ln p(n) = \ln p(n = \tilde{n}) + (n - \tilde{n}) \left. \frac{d \ln p(n)}{dn} \right|_{n=\tilde{n}} + \frac{1}{2} (n - \tilde{n})^2 \left. \frac{d^2 \ln p(n)}{dn^2} \right|_{n=\tilde{n}} + \dots \quad (2.60)$$

Comme l'expansion (2.60) est faite autour du maximum $n = \tilde{n}$ de la fonction $p(n)$, on a

$$\left. \frac{d \ln p(n)}{dn} \right|_{n=\tilde{n}} = 0. \text{ Pour la même raison } \left. \frac{d^2 \ln p(n)}{dn^2} \right|_{n=\tilde{n}} < 0. \text{ On suppose que les termes d'ordre}$$

supérieur dans le développement (2.60) peuvent être négligés. De plus on pose :

$$\ln A = \ln p(n = \tilde{n}) \quad (2.61)$$

et :

$$B = - \left. \frac{d^2 \ln p(n)}{dn^2} \right|_{n=\bar{n}} \quad (2.62)$$

Avec les approximations ci-dessus, on a :

$$\ln p(n) \approx \ln A - \frac{1}{2} (n - \bar{n})^2 B \quad (2.63)$$

ou encore :

$$p(n) \approx A e^{-\frac{1}{2} B (n - \bar{n})^2} \quad (2.64)$$

En utilisant (2.59), on a $\bar{n} = pN = \bar{n}$.

En dérivant deux fois (2.58) :

$$B = - \left. \frac{d^2 \ln p(n)}{dn^2} \right|_{n=\bar{n}} = - \left(\frac{-1}{n} - \frac{1}{N-n} \right) \Big|_{n=\bar{n}} = \frac{1}{Npq} = \frac{1}{\sigma^2} \quad (2.65)$$

, où σ^2 est la variance de n (équation 2.50).

Pour calculer A , le plus simple est d'imposer la condition de normalisation sur la distribution de probabilité :

$$\int_{-\infty}^{+\infty} p(n) dn = 1 \Leftrightarrow A = \frac{1}{\int_{-\infty}^{+\infty} e^{-\frac{1}{2} B (n - \bar{n})^2} dn} = \sqrt{\frac{B}{2\pi}} = \frac{1}{\sqrt{2\pi\sigma^2}} \quad (2.66)$$

Finalement en substituant les valeurs de A et B dans (2.64), on obtient l'expression standard de la distribution de probabilité gaussienne :

$$p(n) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(n - \bar{n})^2 / 2\sigma^2} \quad (2.67)$$




Figure 2.4 distribution gaussienne $\bar{n} = 5$; $\sigma = 1$

On remarque, que c'est une fonction symétrique par rapport à $\bar{n}$.

La distribution gaussienne est donc une approximation continue de la distribution binomiale, valable pour les grandes valeurs de N au voisinage de $n = \bar{n}$. En réalité, elle reste une bonne approximation même pour les valeurs de N assez petites et pour la plupart des valeurs de n comme on peut le voir sur le tableau ci-dessous :

n	$P_{10}(n)$	Approximation gaussienne
0	0.000977	0.001700
1	0.009766	0.010285
2	0.0403945	0.041707
3	0.117188	0.113372
4	0.205078	0.206577
5	0.246094	0.252313

Comparaison entre les valeurs exactes de $P_{10}(n)$ et la distribution gaussienne pour $p = q = 1/2$

Un des résultats les plus importants concernant la distribution gaussienne est que sa largeur relative $\sigma/\bar{n}$ décroît en $N^{-1/2}$. Bien sûr, la distribution binomiale a ce même comportement.

2.8 Théorème de la limite centrale et universalité de la distribution gaussienne

On a vu qu'on pouvait estimer la probabilité d'un événement empiriquement par échantillonnage, c'est à dire en répétant un grand nombre de fois une mesure sur le résultat d'évènements indépendants. Intuitivement, nous savons que si nous effectuons un nombre de plus en plus grand de mesures, la valeur moyenne du résultat calculée approchera la valeur moyenne exacte. Cette idée est appelée *loi des grands nombres*. On peut encore aller plus loin et déterminer la forme analytique de la distribution de probabilité. La forme de cette distribution de probabilité est donnée par le *théorème de la limite centrale*.

Exemple

Supposons que l'on veuille estimer la probabilité d'obtenir la face 1 lors d'un lancer de dé à 6 faces. La réponse est $1/6$. Ce qui signifie que si on effectue N lancers, la face 1 apparaîtra approximativement $N/6$ fois. Que signifie approximativement ? Soit S le nombre total de fois où la face 1 apparaît au cours de N lancers. On écrira :

$$S = \sum_{i=1}^N s_i \quad (2.68)$$

où :

$$s_i = \begin{cases} 1 & \text{si le } i\text{ème lancer donne 1} \\ 0 & \text{sinon} \end{cases} \quad (2.69)$$

Si N est grand, S/N tend vers $1/6$. Comment ce rapport approche-t-il cette limite. On peut répondre empiriquement à cette question, en répétant la série de mesures M fois (Chaque mesure de S correspond à N lancers de dés). La figure 2. 3 montre les résultats pour $M=10000$ avec $N=100$ et avec $N=800$:




Figure 2.3

Distribution de probabilité de la somme S pour $M=10000$ mesures différentes avec $N=100$ et $N=800$. S est le nombre de fois que la face 1 apparaît au cours de N lancers. On trouve $\bar{S} = 16.67$, $\bar{S}^2 = 291.96$ et $\sigma_S = 3.74$ pour $N=100$. Pour $N=800$ $\bar{S} = 133.31$, $\bar{S}^2 = 17881.2$ et $\sigma_S = 10.52$

En revenant au cas général, grâce au théorème de la limite centrale (la démonstration n'est pas possible avec vos connaissances actuelles en mathématiques, donc on admettra le résultat), dans la limite des grands N , on a :

$$p(S) = \frac{1}{\sqrt{2\pi\sigma_S^2}} e^{-(S-\bar{S})^2/2\sigma_S^2} \quad (2.70)$$

avec

$$\bar{S} = N\bar{s} \quad (2.71)$$

$$\sigma_S^2 = N\sigma^2 \quad (2.72)$$

La quantité $p(S)\Delta S$ représente la probabilité que la somme $\sum_{i=1}^N s_i$ soit comprise entre S et $S + \Delta S$. L'équation (2.70) est équivalente au théorème de la limite centrale. Notons que la forme gaussienne n'est valable que pour $N \gg 1$ et pour des valeurs de S au voisinage de sa valeur la plus probable (valeur moyenne).

Le théorème de la limite centrale est l'un des résultats les plus puissants de la théorie des probabilités. Dans sa forme la plus simple, il affirme que *la somme d'un grand nombre de variables aléatoires indépendantes identiquement distribuées, est une variable aléatoire dont la distribution de probabilité tend vers une distribution gaussienne. L'approximation gaussienne est d'autant meilleure que le nombre de termes dans la somme est grand.*

Si S représente maintenant le déplacement unidimensionnel d'un ivrogne en N pas, ou encore, le moment magnétique total d'une assemblée de N spins sans interaction, on obtiendrait des résultats similaires. Ce qui signifie que la marche aléatoire et ses équivalents sont des processus aléatoires *additifs*.

Pour un lancer de dé $\bar{s} = 1/6$, $\overline{s^2} = 1/6$, et $\sigma^2 = 5/36$. Pour N lancers, $\bar{S} = N/6$, $\sigma_S^2 = 5N/36$. On donc bien une erreur relative dans la mesure de S qui décroît comme $\sigma_S/S = \sqrt{5/N}$.

Le théorème de la limite centrale montre pourquoi la distribution gaussienne se rencontre partout dans la nature. Si un processus aléatoire est associé à la somme d'un grand nombre de processus microscopiques similaires, la somme sera distribuée suivant une loi gaussienne, quelle que soit la nature des processus microscopiques. Le théorème de la limite centrale implique que les corps macroscopiques ont des propriétés bien définies, même si leurs constituants ont des propriétés qui changent constamment. Par exemple dans un gaz ou un liquide, la position et la vitesse de chaque molécule change à une fréquence beaucoup plus rapide que toutes les durées typiques de mesure. Pour cette raison, durant une mesure de la pression d'un fluide, il y a tellement de collisions des molécules avec les parois du réservoir que la pression a une valeur moyenne très bien définie. De même, la probabilité que la pression mesurée dévie de sa valeur moyenne est proportionnelle à $\sqrt{1/N}$, où N est le nombre de molécules dans le système. C'est le théorème de la limite centrale qui rend la thermodynamique possible.

2.9 Distribution de Poisson

Revenons à la question de savoir s'il est prudent de voyager en avion ou non. Si la probabilité qu'à un avion de s'écraser au cours d'un vol est $p = 10^{-7}$, alors la probabilité de survivre à un vol d'avion est $1 - p$ (en supposant que lors d'un crash tous les passagers meurent). La probabilité de survivre à N vols est donc $P_N = (1 - p)^N$. Pour $N=400$, $P_N \sim 0.9996$. Notre intuition est vérifiée. Si on vit 80 ans, et qu'on prend 5 fois l'avion par an, on a seulement un risque infime de s'écraser en vol.

Ce type de raisonnement est typique quand la probabilité d'un événement individuel est petite, mais qu'il y a un grand nombre d'essais ; on s'intéresse donc à la probabilité d'occurrence de n événements parmi N essais, dans les conditions où la probabilité d'occurrence d'un événement est très faible. La distribution de probabilité résultante est appelée *distribution de Poisson*. Elle est importante dans l'analyse de nombreux résultats expérimentaux.

Pour obtenir la distribution de Poisson, on part de la distribution binomiale

$$P_N(n) = \frac{N!}{n!(N-n)!} p^n q^{N-n} \quad (2.73)$$

avec la condition $n \ll N$.

En utilisant l'approximation de Stirling :

$$\begin{aligned} \ln \frac{N!}{(N-n)!} &\approx N \ln N - N - (N-n) \ln(N-n) + (N-n) \\ &\approx N \ln N - (N-n) \ln \left[N \left(1 - \frac{n}{N} \right) \right] - n \\ &\approx N \ln N - (N-n) \ln N + (N-n) \frac{n}{N} - n \\ &\approx n \ln N \end{aligned} \quad (2.74)$$

On a négligé le terme d'ordre 2 en $\frac{n^2}{N}$ et où on a utilisé le développement $\ln(1-x) \approx -x$ si $x \ll 1$. D'où :

$$\frac{N!}{n!(N-n)!} \approx e^{n \ln N} = N^n \quad (2.75)$$

Pour $p \ll 1$ $\ln(1-p) \approx -p$, $e^{\ln(1-p)} = 1-p \approx e^{-p}$, $(1-p)^{N-n} \approx e^{-p(N-n)} \approx e^{-pN}$. En utilisant ces approximations, on trouve :

$$P_N(n) \approx \frac{N^n}{n!} p^n e^{-pN} = \frac{\bar{n}^n}{n!} e^{-\bar{n}} \quad (\text{distribution de Poisson}) \quad (2.76)$$

où

$$\bar{n} = pN \quad (2.77)$$

On vérifie aisément que la distribution de Poisson est correctement normalisée :

$$\sum_{n=0}^{+\infty} P_N(n) = e^{-\bar{n}} \sum_{n=0}^{+\infty} \frac{\bar{n}^n}{n!} = e^{-\bar{n}} e^{\bar{n}} = 1 \quad (2.78)$$

Appliquons la distribution de Poisson au problème de la survie en vol par avion. On veut connaître la probabilité de ne jamais s'écraser, i.e. $P(n=0)$. $\bar{n} = 10^{-7} \times 400 = 4 \times 10^{-5}$ pour $N = 400$ vols. Donc la probabilité de survie vaut $P(0) = e^{-\bar{n}} \approx 0.996$. $P(0) = e^{-\bar{n}} = 0.99996$ pour $N = 400$, on obtient le même résultat qu'avec la loi binomiale.

2.10 Distribution exponentielle

La distribution de Poisson est étroitement liée à la distribution exponentielle comme on le verra dans ce paragraphe. On considère une suite d'événements similaires et aléatoires, et on note $t_1, t_2, \dots$ les dates auxquelles chaque événement successif a lieu. Un exemple de telles suites sont les dates auxquelles on reçoit un coup de téléphone, ou celles où un compteur Geiger mesure la désintégration d'un noyau radioactif etc. On veut caractériser la séquence d'événements sur un temps T beaucoup plus grand que tous les intervalles $t_i - t_{i-1}$. On suppose aussi que le nombre moyen d'événements se produisant par unité de temps est λ . On suppose que les événements sont aléatoires et indépendants les uns des autres. Connaissant λ , on veut déterminer la distribution de probabilité $w(t)$ de l'intervalle t entre deux événements successifs. On sait que si un événement se produit à la date $t = 0$, la probabilité pour que l'événement suivant se produise dans l'intervalle de temps $[0, t]$ est par définition : $\int_0^t w(t') dt'$. La probabilité qu'aucun événement ne se produise dans ce même intervalle de temps est : $1 - \int_0^t w(t') dt'$. Alors la probabilité que l'intervalle de temps entre les deux événements successifs soit compris entre la date t et $t + \Delta t$ est :

$$w(t) \Delta t = \left(1 - \int_0^t w(t') dt' \right) \times \lambda \Delta t \quad (2.79)$$

(2.79) exprime que la probabilité recherchée est le produit de la probabilité qu'aucun événement n'ait lieu dans l'intervalle $[0, t]$ par la probabilité que l'événement ait lieu dans l'intervalle Δt . En simplifiant par Δt chaque membre de l'équation, puis en la différentiant par rapport à t , on obtient :

$$\frac{dw}{dt} = -\lambda w \quad (2.80)$$

qui s'intègre en :

$$w(t) = Ae^{-\lambda t} \quad (2.81)$$

La constante A s'obtient par la condition de normalisation :

$$\int_0^\infty w(t)dt = 1 \Leftrightarrow A = \lambda \quad (2.82)$$

Et on obtient la distribution exponentielle

$$w(t) = \lambda e^{-\lambda t} \quad (2.83)$$

La distribution exponentielle conduit naturellement à la distribution de Poisson. On divise le long intervalle de temps T en n plus petits intervalles $t = T/n$. Quelle est la probabilité que 1, 2, 3, ... évènements se produisent dans l'intervalle de temps t connaissant λ ? Quel est le nombre moyen d'évènements par unité de temps ? Nous allons montrer que la probabilité que n évènements se produisent dans l'intervalle de temps t est donnée par la distribution de Poisson :

$$P_n(t) = \frac{(\lambda t)^n}{n!} e^{-\lambda t} \quad (2.84)$$

Considérons d'abord le cas $n = 0$. La probabilité qu'aucun événement ne se produise dans l'intervalle t est donné d'après (2.83) par :

$$P_{n=0}(t) = 1 - \int_0^t \lambda e^{-\lambda t'} dt' = e^{-\lambda t} \quad (2.85)$$

Pour $n = 1$, il y a exactement 1 événement dans l'intervalle t . Cet événement doit avoir lieu à une date t' choisie au hasard et de manière équiprobable dans l'intervalle $[0, t]$. Cette date étant choisie, aucun événement ne se produit dans l'intervalle $[t', t]$. On a donc, en utilisant la règle d'addition des probabilités:

$$P_1(t) = \int_0^t w(t') P_0(t - t') dt' = \int_0^t \lambda e^{-\lambda t'} e^{-\lambda(t-t')} dt' = \lambda t e^{-\lambda t} \quad (2.86)$$

En généralisant, si n évènements se produisent dans l'intervalle $[0, t]$, le premier doit avoir lieu à une date t' quelconque comprise dans $[0, t]$, et exactement $(n-1)$ se produisent dans l'intervalle $[t', t]$, soit :

$$P_n(t) = \int_0^t w(t') P_{n-1}(t - t') dt' = \int_0^t \lambda e^{-\lambda t'} P_{n-1}(t - t') dt' \quad (2.87)$$

On peut alors établir l'expression (2.84) en utilisant la relation de récurrence (2.87). On vérifie que P_0 et P_1 qu'on a déterminées directement vérifient bien (2.84) et on suppose que la relation (2.84) est vraie à l'ordre $n-1$. En utilisant (2.87), on a :

$$P_n(t) = \frac{\lambda^n}{(n-1)!} e^{-\lambda t} \int_0^t (t-t')^{n-1} dt' = \frac{(\lambda t)^n}{n!} e^{-\lambda t} \quad (2.88)$$

CQFD